Activation Function

미래연구소 16기 4주차

0. 배경지식 – Vanishing Gradient

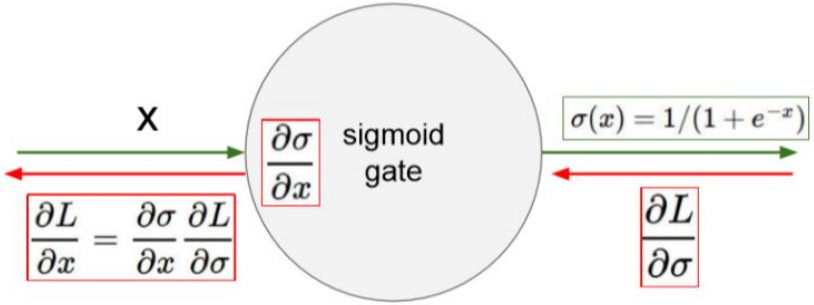

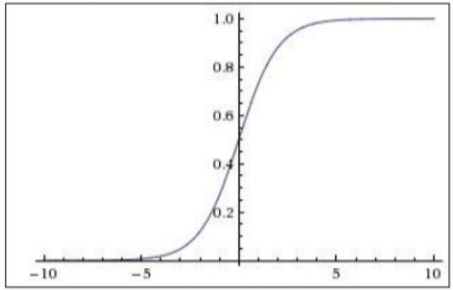

What happens when x = -10?
What happens when x = 0?
What happens when x = 10?

0. 배경지식 – Vanishing Gradient

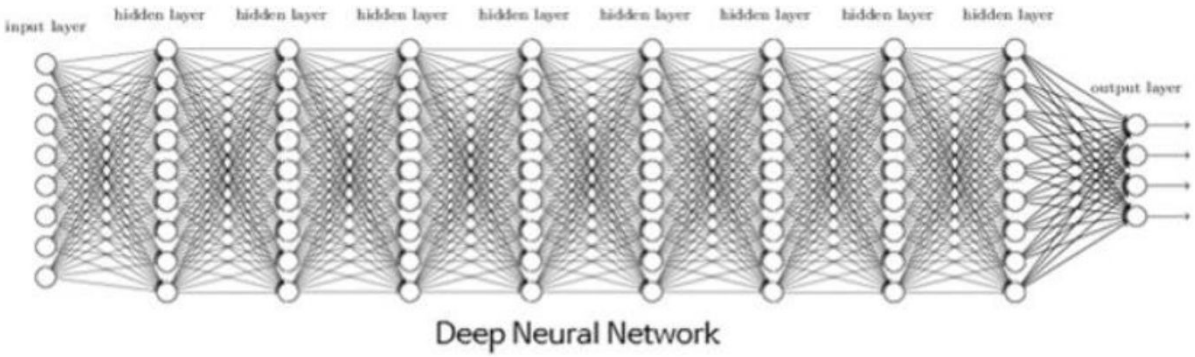

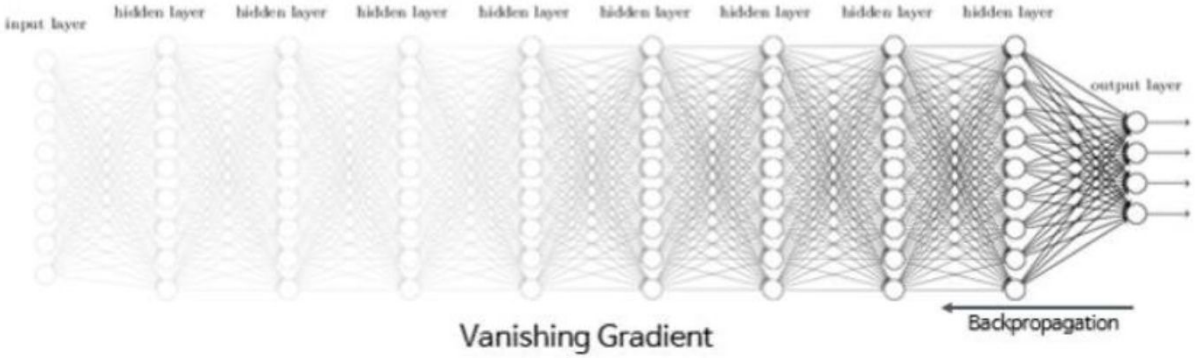

0. 배경지식 – Vanishing Gradient

$$\frac{dJ}{dW^{[1]}} = \frac{1}{m}(W^{[2]T}dZ^{[2]} * g^{[1]}(Z^{[1]}))X^T \longrightarrow \textbf{Vanishing gradient } (g' \fallingdotseq 0 \Rightarrow \frac{dJ}{dW} \fallingdotseq 0)$$

1) 현상 이해

activation의 미분 계수 (접선 기울기)가 0에 가까우면

⇒ **dJ/dW의 감소**

⇒ **gradient descent가 잘 일어나지 않음 (학습이 잘 일어나지 않음)**

2) 용어 이해

1> saturation : weight의 update가 잘 일어나지 않는 현상

2> vanishing gradient : gradient가 0에 가까워지는 (소실되는 현상)

1. Sigmoid

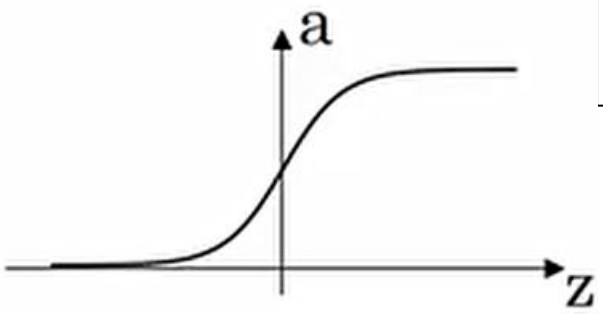

1) 0 < g(z) < 1

장점 1: binary classification의
output layer라는 특수한 상황에 적합

$$g(z) = -\frac{1}{1+e^{-z}}$$

$$g'(z) = a(1-a)$$

2) g'(z)가 0에 가까운
구간이 많다.

단점 2: gradient descent 속도 저하 ↓

2. tanh (hyperbolic tangent)

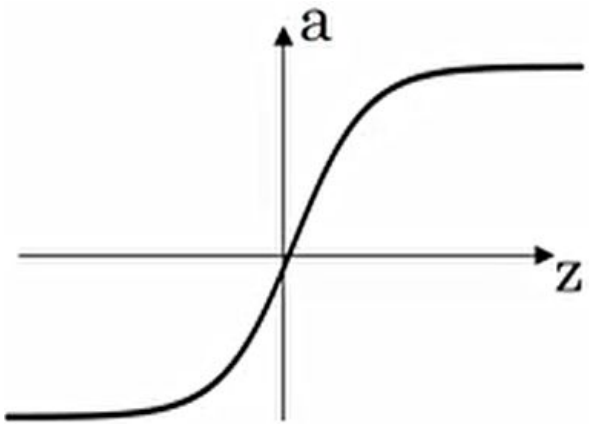

1) -1 < g(z) < 1

2) g'(z)가 0에 가까운 구간이 많다.

(0 < g'(z) < 1)

장점 1: sigmoid보다는 vanishing gradient 가 덜하다. (g'(z)의 최댓값이 1)

단점 1: gradient descent 속도 저하↓

$$g(z) = -\frac{e^z - e^{-z}}{e^z + e^{-z}}$$

$$g'(z) = (1 - a^2))$$

3. ReLU (Rectified Linear Unit)

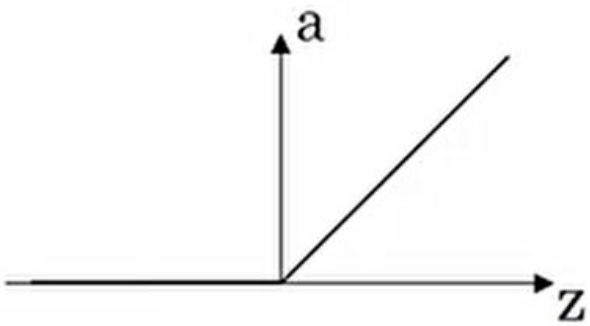

$$g(z) = \begin{cases} z & z > 0 \\ 0 & z < 0 \end{cases}$$

$$g'(z) = \begin{cases} 1 & z > 0 \\ 0 & z < 0 \end{cases}$$

1) g'(z) = 1인 구간이 절반이다.

장점 1: sigmoid, tanh의 vanishing gradient 문제 해결

단점 1: 그래도 절반이 gradient가 0 (dying ReLU 현상)

4. Leaky ReLU

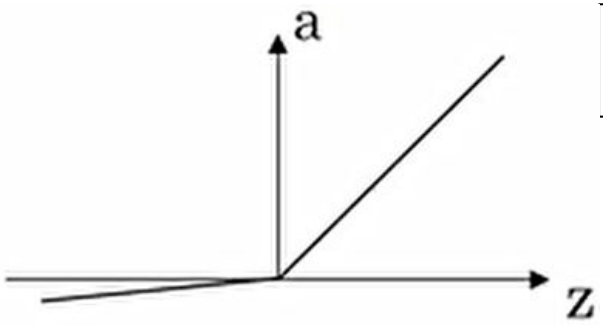

1) gradient가 0인 구간이 없다.

장점 1: dying ReLU 현상을 해결
(GAN 과 같은 train이 어려운 경우에 사용)

$$g(z) = \begin{cases} z & z > 0 \\ 0.01z & z < 0 \end{cases}$$

$$g'(z) = \begin{cases} 1 & z > 0 \\ 0.01 & z < 0 \end{cases}$$

5. output layer의 activation function

	Regression	Binary classification	multi-class classification
output layer의 activation function		sigmoid	softmax

softmax는 C3 W3에 있으나 6주차에 소개할 계획입니다.

6. activation이 non-linear해야 하는 이유

0. 딥러닝은 거대한 합성함수이다.

1. activation이 linear하다.

1) 선형변환이다. = 일차함수이다.
2) 선형변환을 연속하면(일차함수를 계속 합성하면) 일차함수 꼴이 나온다.
3) 딥러닝은 그러면 안 된다. ex> binary에게 가장 이상적인 activation = step function
4) data를 고차원 공간에 두고 이를 함수로 구분 짓는 일 -> 구분을 위해 왜곡된 함수가 필요 (하지만 일차함수는 왜곡이 불가능)

2. non-linear activation이 필요한 이유

1) 그림 자료 -> 다양한 모양의 함수를 만들 수 있다.
2) w, b가 gradient descent에 따라 변하면서 최적의 딥러닝 함수를 찾는다.
3) 선형함수를 쓰면 이런 역할 불가능

3. ReLU / Leaky ReLU