Underfitting vs Overfitting

미래연구소 16기 5주차

1. Fit이란?

1) train의 동의어
(통계 쪽에서는 train이란 용어를, CS에서는 fit이란 용어를 사용)

2) (행동) 특정 data를 학습하는 과정

3) (현상) training set 뿐 아니라 test set까지도 잘 예측하는 상황

2. Underfitting vs overfitting

Week 4 Assignment에서

hidden unit이 많아질수록

training data에 잘 맞게 모양이 다양해지는 현상을 연상하면

뒤에 이어지는 내용 이해하는데 도움이 됩니다.

Epoch (학습 정도) 관점

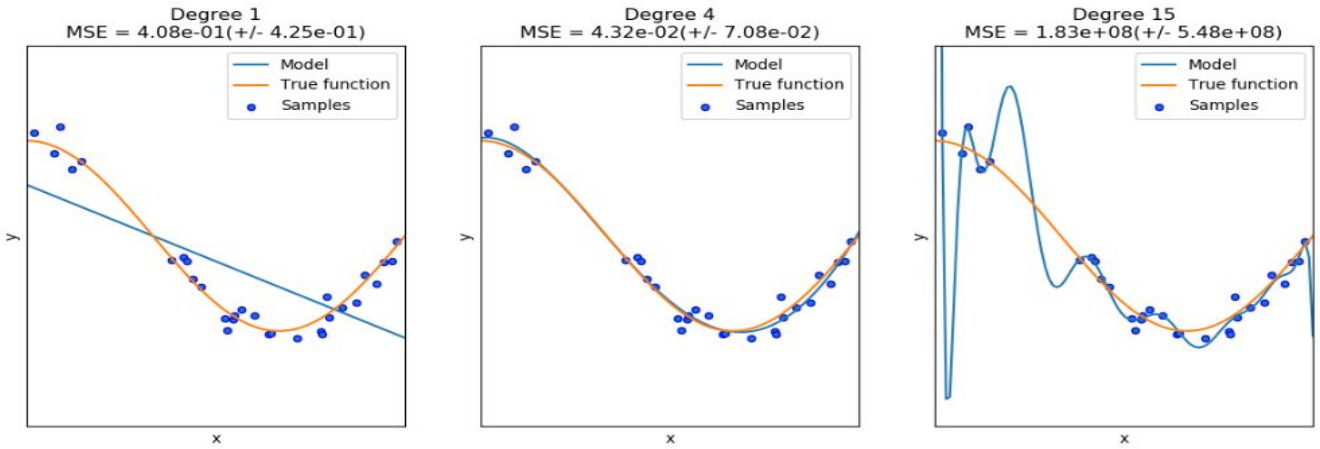

주황 선 - 실제 모든 data의 분포
(우리는 모르는 상태)

파란 점 - training data
(이 점으로 학습하고 예측)

파란 선- 학습을 통해 예측
(가설 함수 = 딥러닝 모델)
(forward propagation)

1> underfit: 학습 초반 모델은 initialization 직후여서 최적의 parameter가 아닌 상황이다
- **그래서 예측을 잘 못하는 상황**

2> fit: train할수록 점점 주어진 training data를 잘 맞추게 된다.
- **하지만 현재 상황이 향후 unseen data에도 잘 맞을지 모른다.**

3> overfit: 그래서 과도하게 학습을 하다보니 향후 존재할 unseen data는 빗나가게 된다.

=> 그래서 중간중간 학습하지 않는 data로 overfit을 확인해야하고 그래서 validation set 설정

https://scikit-learn.org/stable/auto_examples/model_selection/plot_underfitting_overfitting.html

모델의 크기(layer, unit) 관점

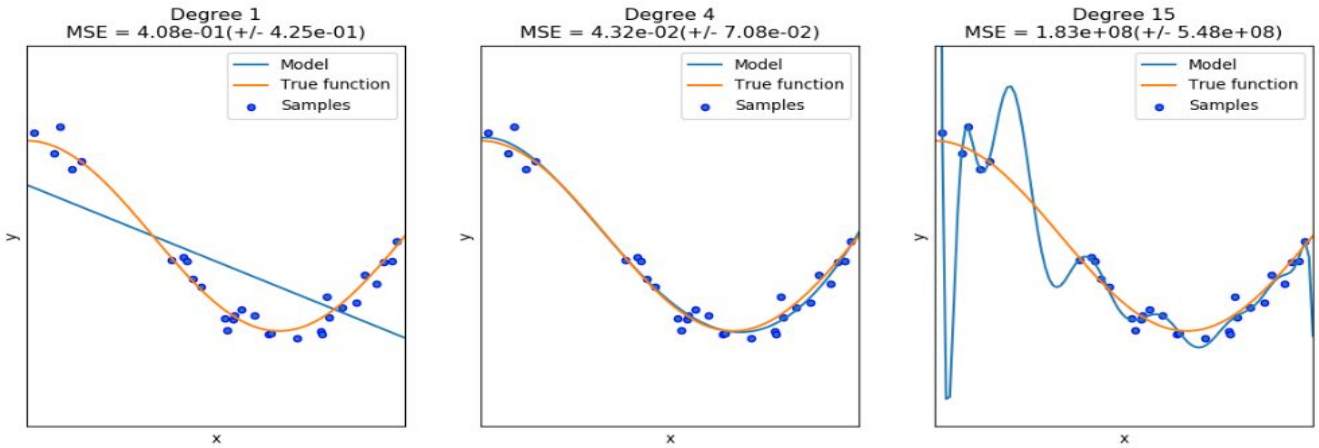

주황 선 - 실제 모든 data의 분포
(우리는 모르는 상태)

파란 점 - training data
(이 점으로 학습하고 예측)

파란 선- 학습을 통해 예측
(가설 함수 = 딥러닝 모델)
(forward propagation)

1> underfit: 가벼운 모델은 선형에 가깝다 (비선형 activation이 적게 합성되어서)
- **그래서 예측을 잘 못하는 상황**

2> fit: 모델이 복잡해질수록 점점 주어진 training data를 잘 맞추게 된다.
- **하지만 현재 상황이 향후 unseen data에도 잘 맞을지 모른다.**

3> overfit: 그러다가 모델은 너무 거대하게 키우면 향후 존재할 unseen data는 빗나가게 된다.

=> 그래서 중간중간 학습하지 않는 data로 overfit을 확인해야하고 그래서 validation set 설정

https://scikit-learn.org/stable/auto_examples/model_selection/plot_underfitting_overfitting.html

2. Underfitting vs overfitting

아까 상황을 graph로 표현

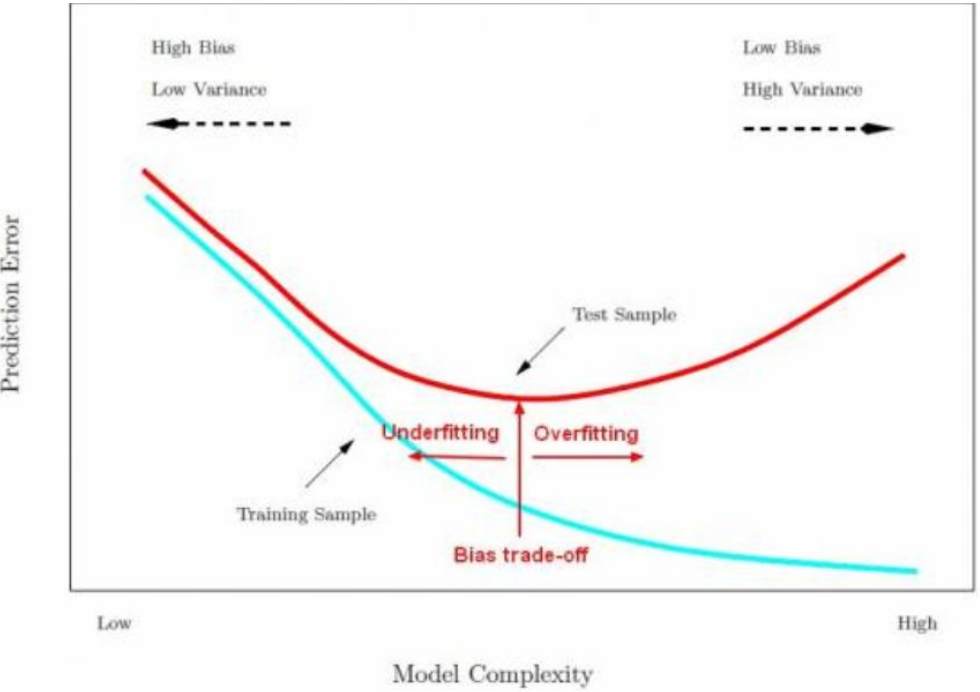

1> 처음에는 training set, val set 모두 못 맞힌다.

2> 점점 둘다 잘 맞힌다.

3> 과도하게 training set에 맞게 모델이 변하다보니 val set을 잘 못 맞힌다.

bias, variance 개념 잘 이해 못해도 괜찮다.

중요한 건

1> 어떤 문제인지 파악하는 능력

2> 그에 따른 해결책이 무엇인지?

bias : 참 값들과 추정 값들의 차이

variance : 추정값들의 흩어진 정도

3. C2 W1 L2에 대한 이해 1) 1번째 예시

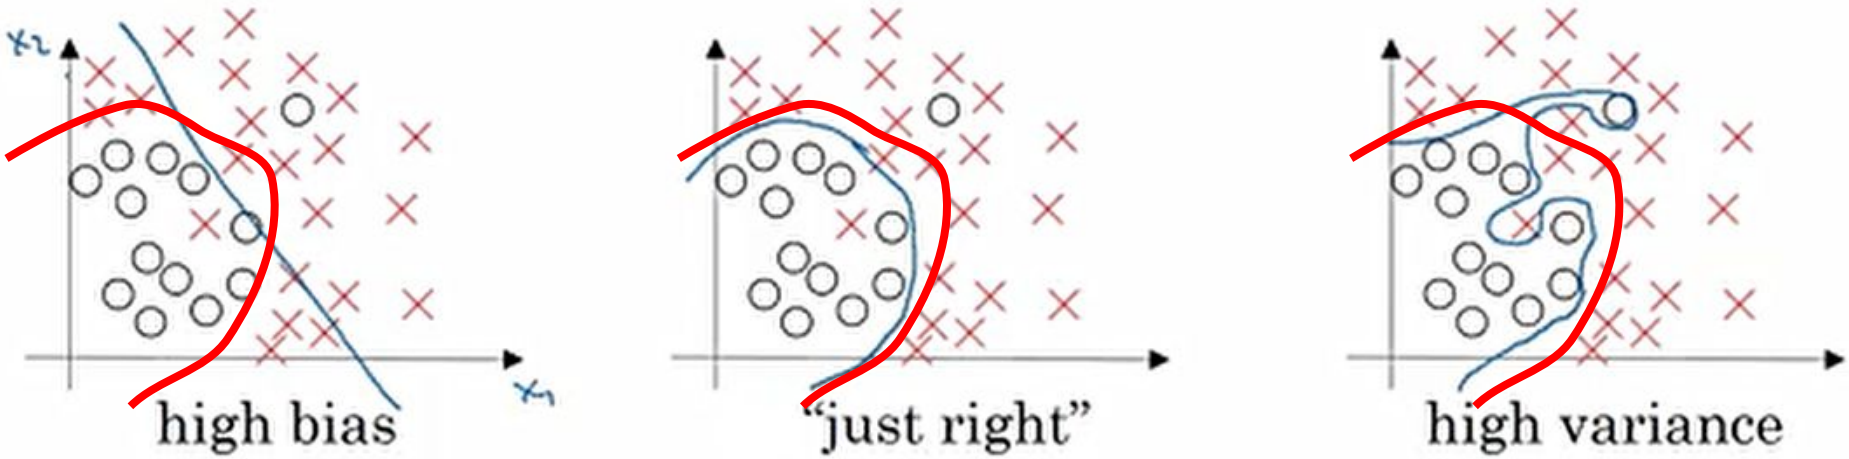

높은가? 낮은가?	1번	2번	3번
training error			
dev error			

3. C2 W1 L2에 대한 이해 1) 1번째 예시

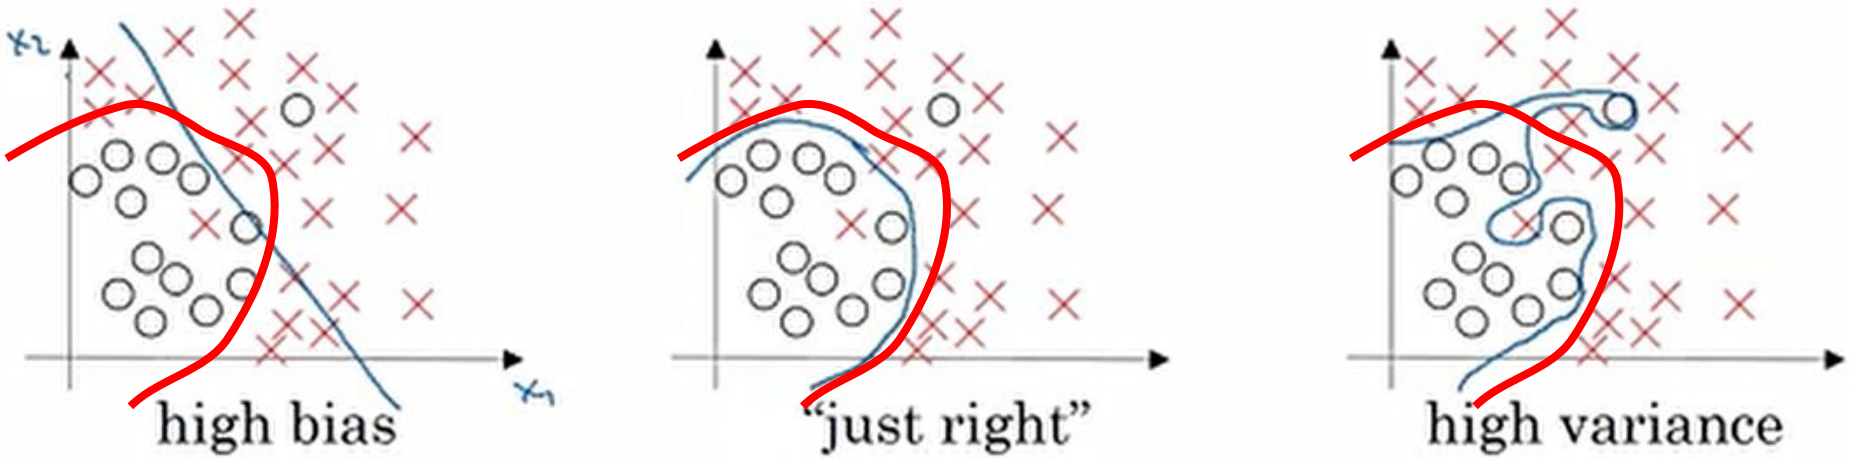

높은가? 낮은가?	1번	2번	3번
training error	높다	낮다	낮다
dev error			

3. C2 W1 L2에 대한 이해 1) 1번째 예시

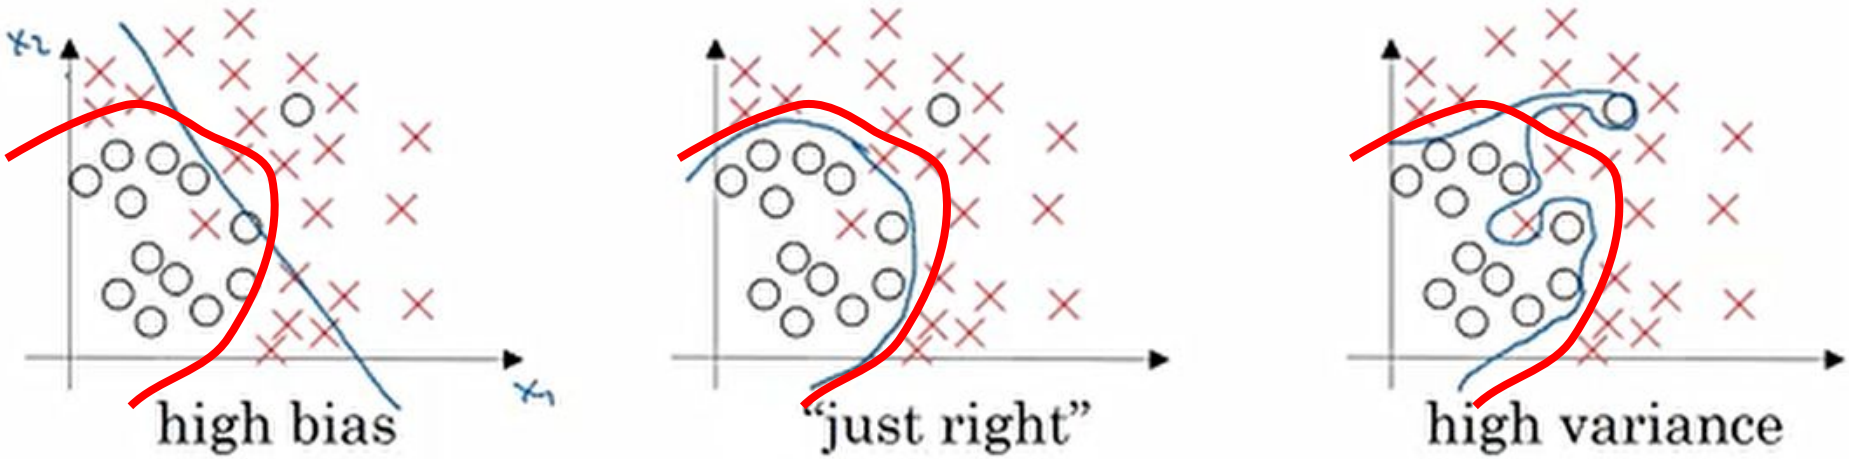

높은가? 낮은가?	1번	2번	3번
training error	높다	낮다	낮다
dev error	높다	낮다	높다

3. C2 W1 L2에 대한 이해 1) 1번째 예시

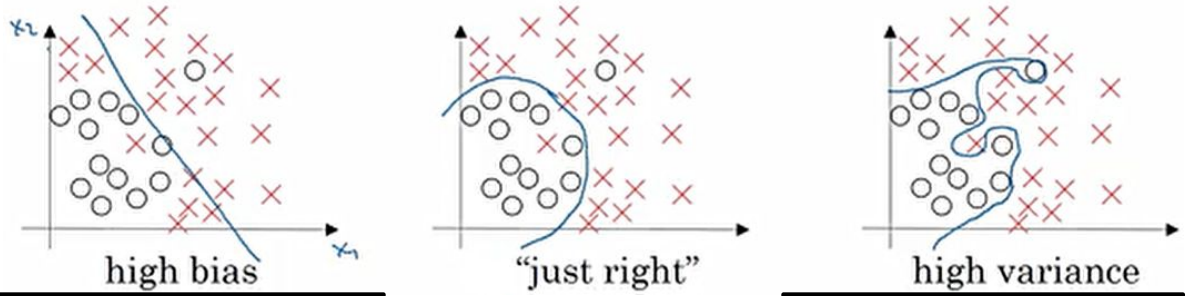

	underfitting		overfitting
높은가? 낮은가?	1번	2번	3번
training error	높다	낮다	낮다
dev error	높다	낮다	높다

3. C2 W1 L2에 대한 이해 2) 2번째 예시

Cat classification

optimal error = 0%

Train set error:	1%	15%	15%	0.5%
Dev set error:	11%	16%	30%	1%
	high variance	high bias	high bias & high variance	low bias low variance

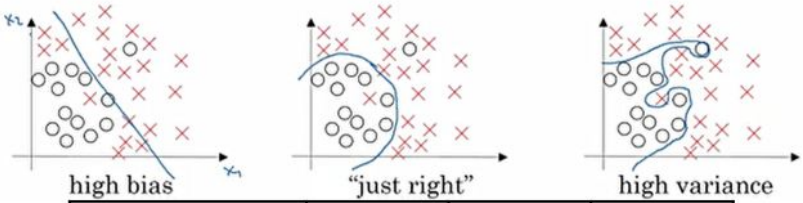

높은가? 낮은가?	1번	2번	3번
training error	높다	낮다	낮다
dev error	높다	낮다	높다

각각 몇 번과 대응되나요?

결론: 각 case 별로 어떤 문제에 처해있는지 파악할 수 있어야 한다.

4. 연습

	case 1	case 2	case 3	case 4
optimal accuracy	99%	99%	99%	99%
training set accuracy	80%	98%	95%	60%
validation set accuracy	75%	97%	70%	50%