Mini-Batch Gradient Descent

미래연구소 16기 7주차

0. 기존에 배운 Training Data의 기본 단위

=> batch : 우리가 가진 전체 training data

$$W \cdot X + b = W \cdot \begin{bmatrix} \vdots & \vdots & & \vdots \\ X^{(1)} & X^{(2)} & \cdots & X^{(m)} \\ \vdots & \vdots & & \vdots \end{bmatrix} + b$$

그러므로 위와 같이 1번 학습할 때(gradient descent),
data 전체(batch)를 사용합니다.

그런데 왜 아래와 같이 1 epoch을 한 번에 끝내지 못할까요?

저 50000개의 data를 train하는데 1563이라는 숫자는 무엇일까요?

```
history = model.fit(x_train, y_train, validation_split=1/6, epochs=5)
```

```
Epoch 1/5
1563/1563 [==============================] - 5s 3ms/step - loss: 0.5618 - accuracy: 0.8347 - val_loss: 0.1687 - val_accuracy: 0.9503
Epoch 2/5
 986/1563 [=================>............] - ETA: 0s - loss: 0.1595 - accuracy: 0.9541
```

1. Mini-batch 1) 정의

1> mini-batch : 단일 train iteration에서 gradient descent하는데
사용하는 data의 총 개수

(batch가 data 전체이며, 그 중 일부씩만 학습하므로 'mini-batch'라고 부릅니다.)

2> epoch : data 전체를 train한 횟수

(모든 mini-batch를 학습 완료 = 1개 epoch 종료)

1. Mini-batch 2) 예시

- batch = 5,000,000개
- mini-batch = 1,000개

$$X = \left[\underbrace{X^{(1)} \cdots X^{(1000)}}_{X^{\{1\}}} \;\middle|\; \underbrace{X^{(1001)} \cdots X^{(2000)}}_{X^{\{2\}}} \;\middle|\; \cdots X^{(m)} \right]$$

(n_x, m) $\quad$ $(n_x, 1000)$ $\quad$ $(n_x, 1000)$ $\quad$ $X^{\{5000\}}$ $(n_x, 1000)$

$$Y = \left[Y^{(1)} \cdots Y^{(1000)} \;\middle|\; Y^{(1001)} \cdots Y^{(2000)} \;\middle|\; \cdots Y^{(m)} \right]$$

2. Mini-Batch Gradient Descent 1) 용어 정리 (이론)

1> Batch Gradient Descent : 한 번에 모든 data를 train

2> Mini-Batch Gradient Descent : 한 번에 mini-batch씩만 train

3> Stochastic Gradient Descent (SGD) : 한 번에 1개의 data씩만 train

하지만 이론에서 쓰는 용어와 코딩에서 쓰는 용어가 약간씩 다릅니다.

코딩에서 쓰는 용어를 기준으로 설명하겠습니다.

2. Mini-Batch Gradient Descent 2) 용어 정리 (이론)

~~1> Mini-Batch~~

1> batch_size : 단일 train iteration에서 gradient descent하는데 사용하는 data의 총 개수

~~2> Mini-Batch Gradient Descent~~

2> SGD + batch_size가 1 이상 : 한 번에 batch_size씩만 train

batch_size라는 개념에 대해 이해하는 것이 생소할 수 있습니다.

쉽게 이해하기 위해서 ‘선거와 출구 조사’를 먼저 떠올려보겠습니다.

2. Mini-Batch Gradient Descent 3) batch_size

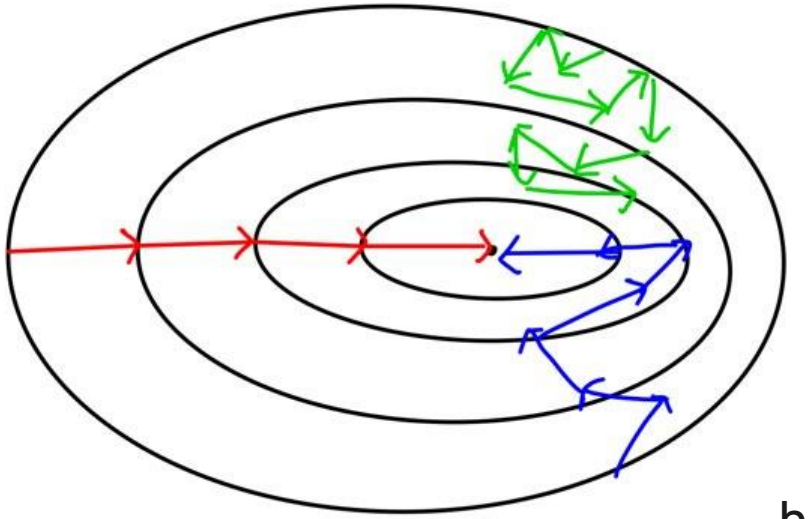

batch_size

- large
- medium
- small

batch_size가 클수록
더 정확한 gradient를 계산하는 경향이 있다.

2. Mini-Batch Gradient Descent 4) batch_size 관련 Tip

1> 2의 거듭제곱으로 설정합니다.

2> batch_size는 클수록 좋습니다. (OOM이 일어나지 않을 정도로 크면 됩니다.)

3> 대체적으로 최소 32이상으로 설정합니다.

4> batch_size ↓ = noise = regularization 효과를 줄 수 있다.
(하지만 그 효과가 적기 때문에 overfitting을 막기 위해 batch_size를 조절하지는 않습니다.)