Recurrent Neural Network

미래연구소 16기 9주차

CNN보다 RNN이 이해하기 어렵다고 생각합니다.

이해가 잘 안 되시는 분들은
1~5주차에 배운 Fully-Connected Layer의 shape들을 다시 복습하시고 RNN 자료 다시 한 번 공부해주시기 바랍니다.

1. RNN의 기본 단위

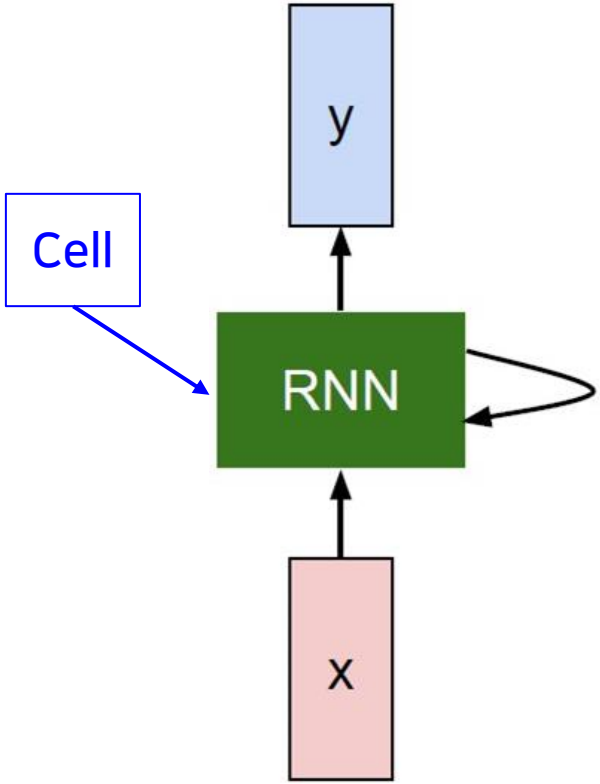

1) RNN은 여러 개의 cell로 구성되어 있다.

2) Cell의 input
- x_t: 해당 시점의 input feature
- h_t-1: 이전 cell의 state 값

3) Cell의 output
- h_t: cell에서의 연산 결과

단위가 큰 구조부터 익히고
점차 작은 구조를 보겠습니다.

2. RNN의 종류

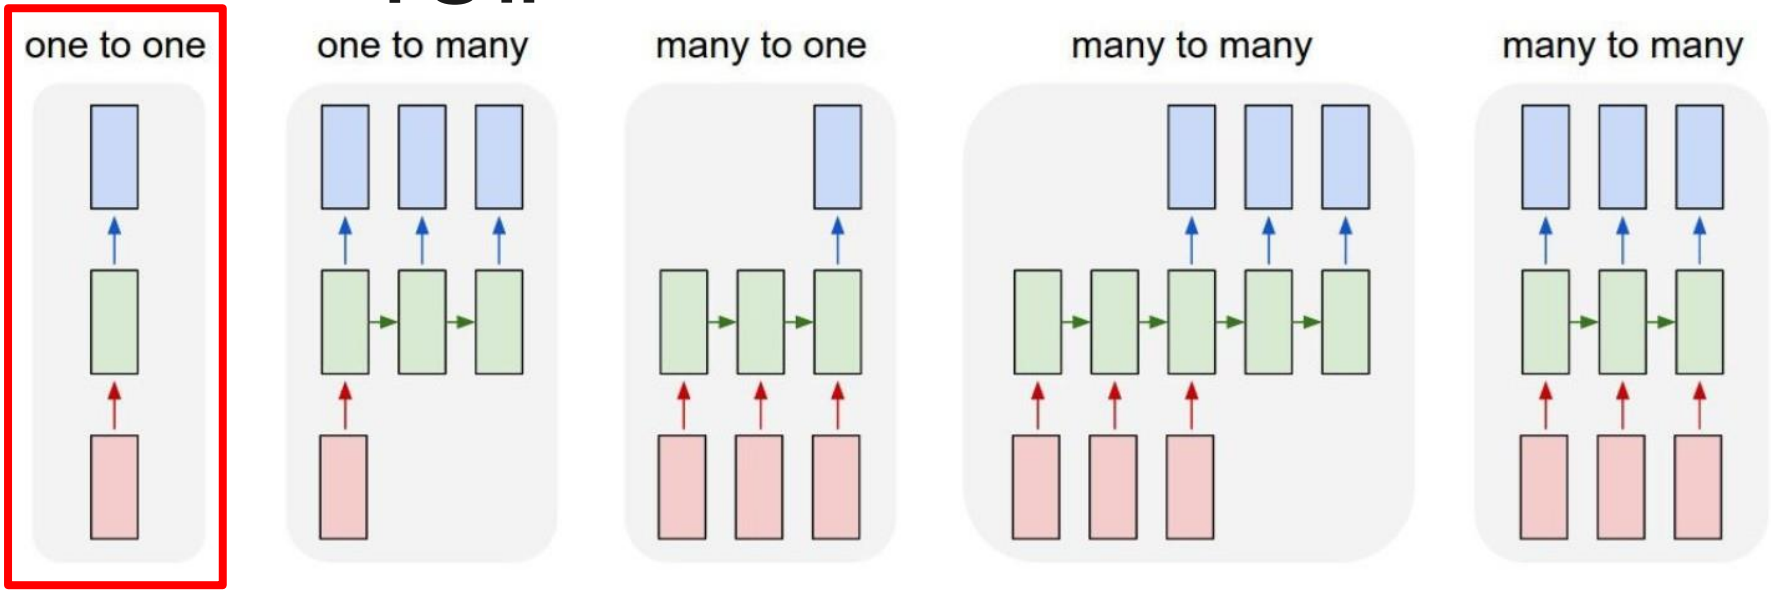

0) Fully-Connected Layer
이 모형이 그동안 배운 Dense Layer입니다.
(input feature 개수와 hidden unit 개수가 생략된 표현입니다.)

2. RNN의 종류

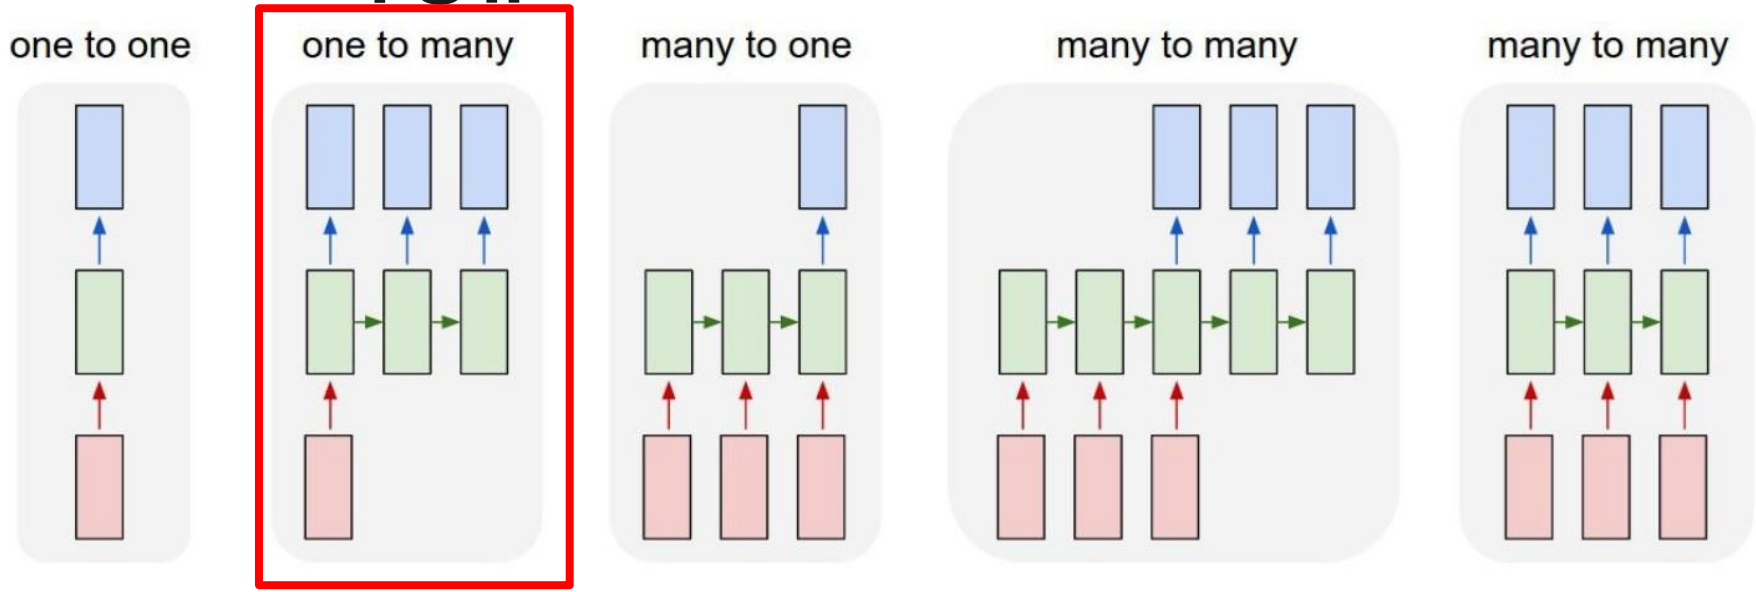

1) Image Captioning
sequential하지 않은 data(image)를 input으로 받고
sequential한 output(text)을 출력

2. RNN의 종류

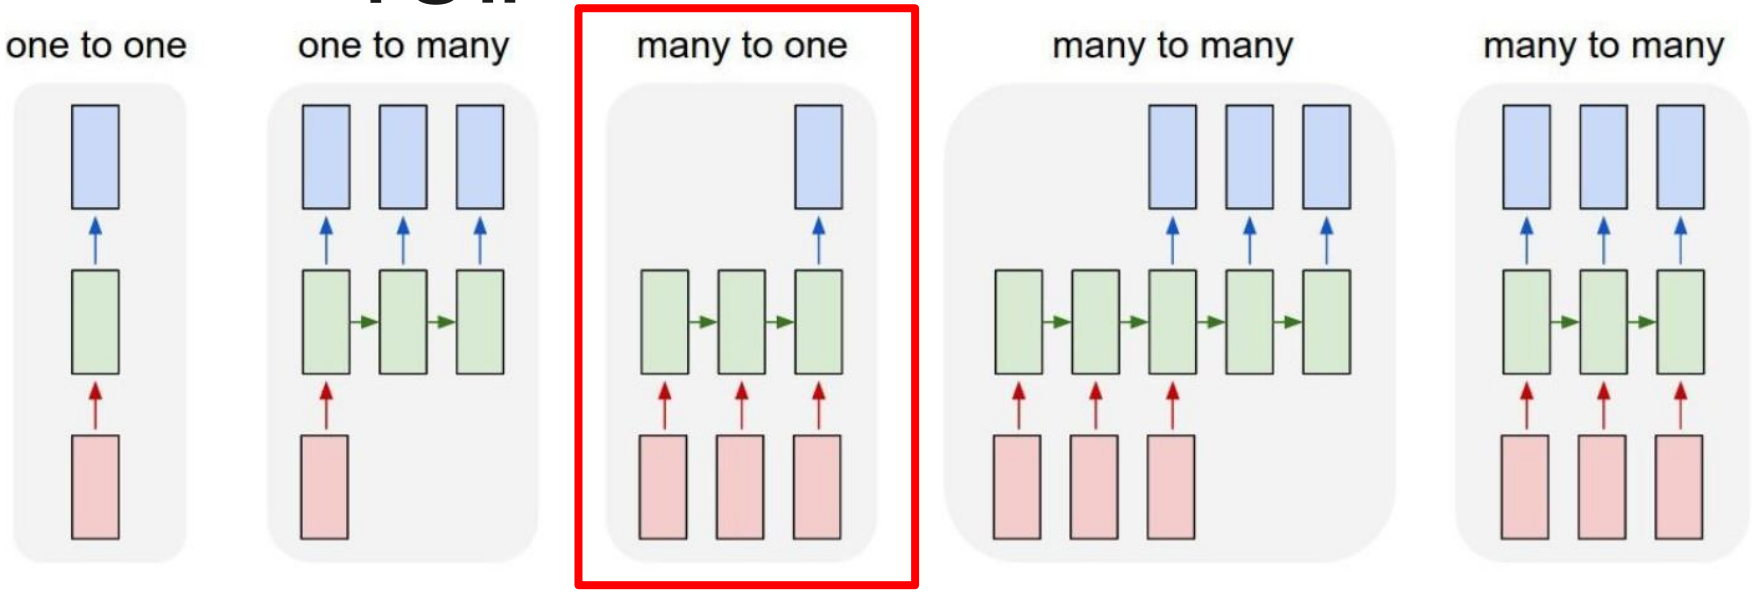

2) Sentiment Classification

2. RNN의 종류

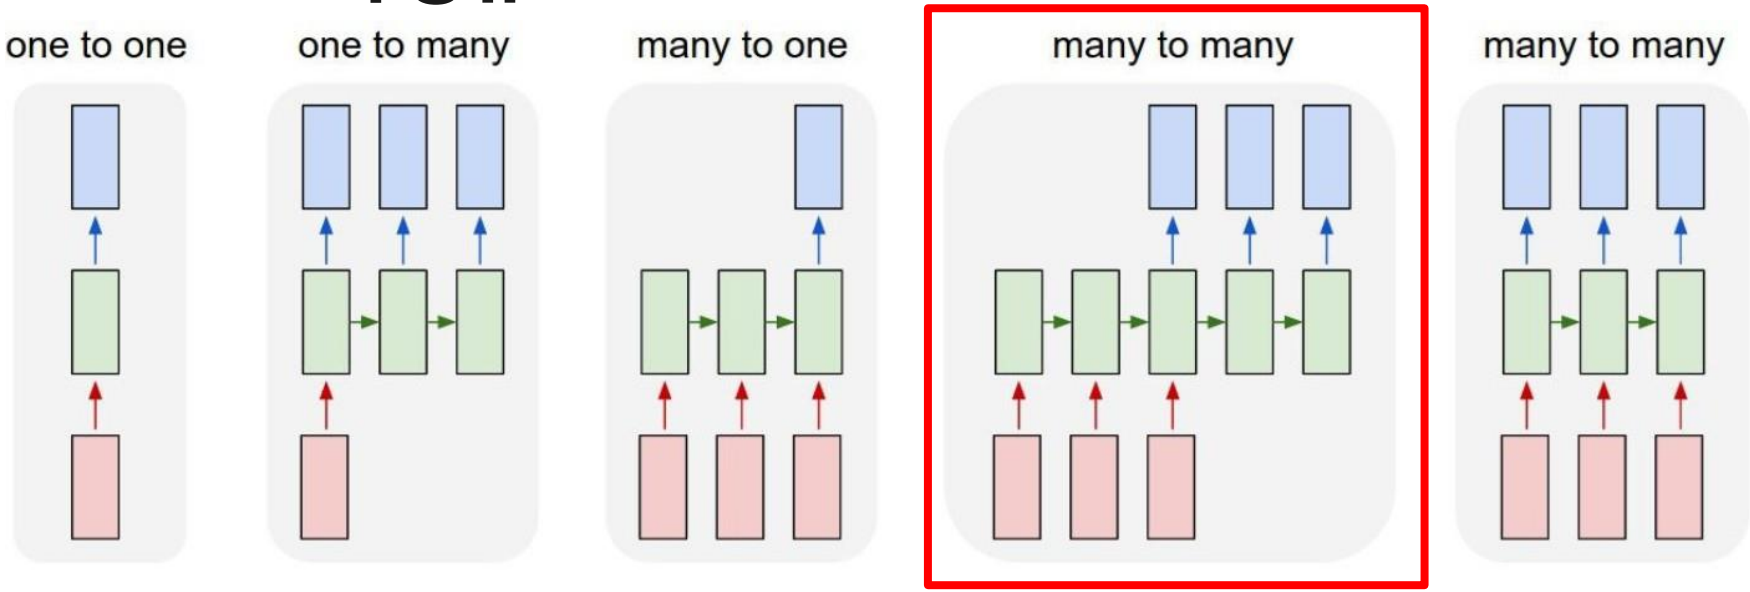

3) Machine Translation
문장을 끝까지 읽은 시점부터
번역된 문장을 출력

2. RNN의 종류

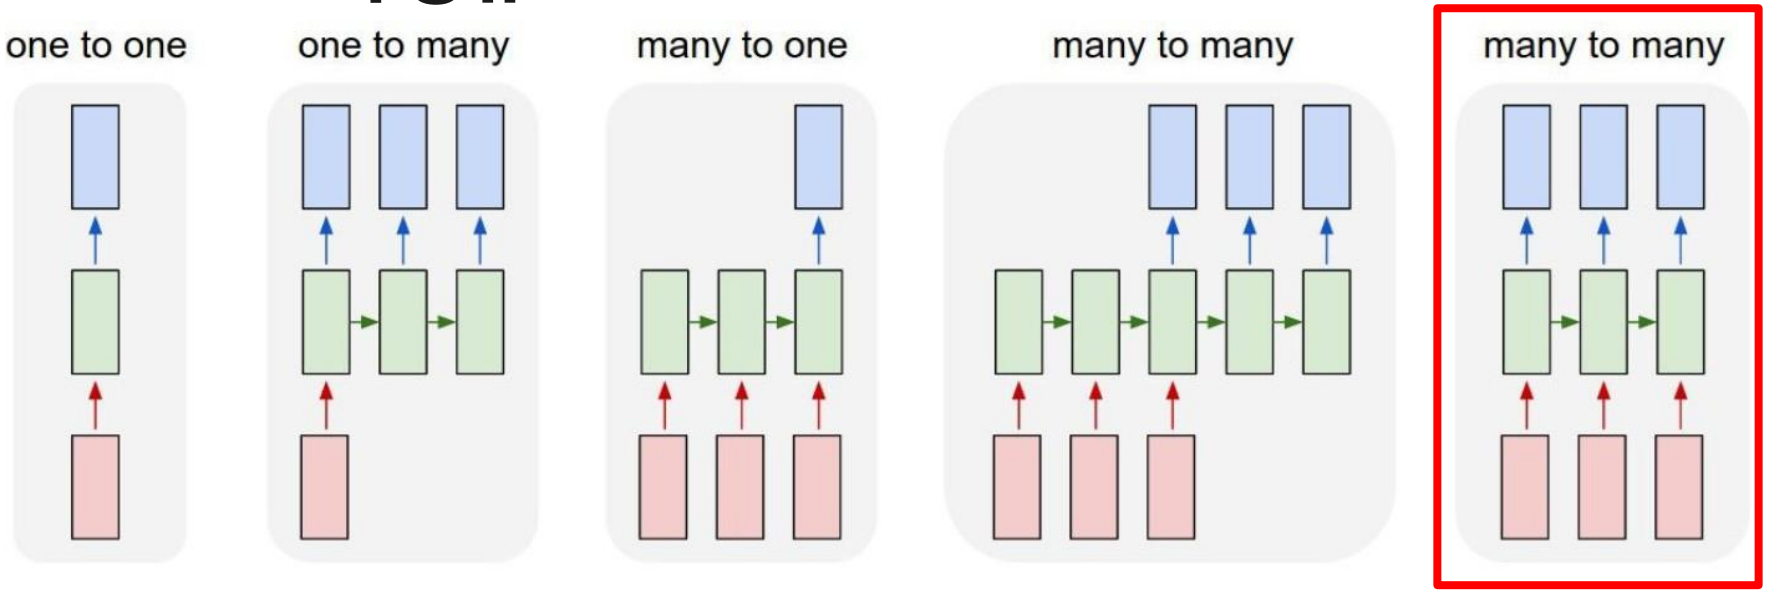

4) Video Classification
(아까와 달리 영상을 다 본 시점까지 가지 않고)
과거부터 현재까지의 image를 통해 output 값을 출력

3. RNN 용어 정리 1) X

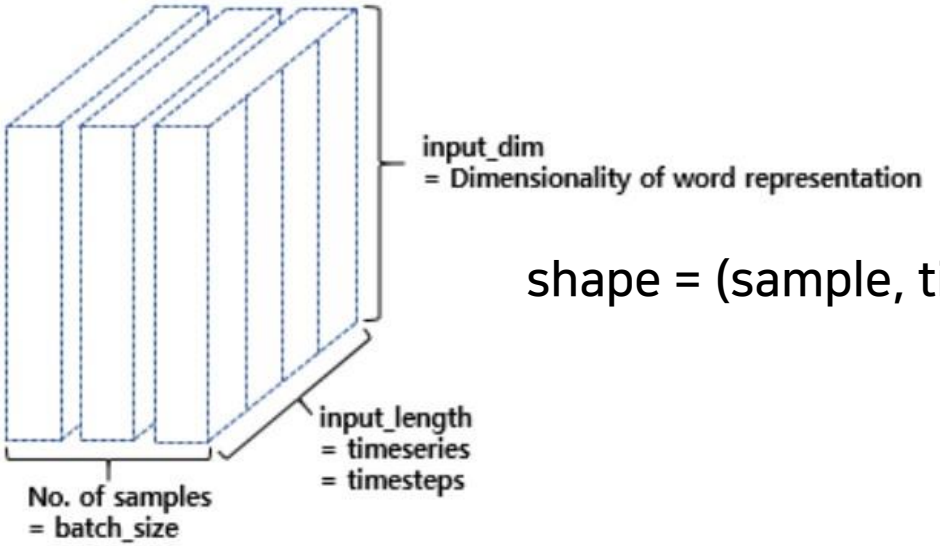

shape = (sample, time_step, input_dim)

1> sample: sample 개수 (1회 train 기준 = batch_size)
2> time_step = input_length: 어느 정도의 시간을 고려할 것인가
3> input_dim: input data의 feature 수

	Date	Open	High	Low	Close	Volume	Adj Close
0	6/29/2010	19.000000	25.00	17.540001	23.889999	18766300	23.889999
1	6/30/2010	25.790001	30.42	23.299999	23.830000	17187100	23.830000
2	7/1/2010	25.000000	25.92	20.270000	21.959999	8218800	21.959999
3	7/2/2010	23.000000	23.10	18.709999	19.200001	5139800	19.200001
4	7/6/2010	20.000000	20.00	15.830000	16.110001	6866900	16.110001

주식 data에서 각 항목이 어떤 것을 지칭할까요?

1> sample: 빨간 박스가 data 1개라면
2> time_step = input_length:
3> input_dim:

3. RNN 용어 정리 1) X

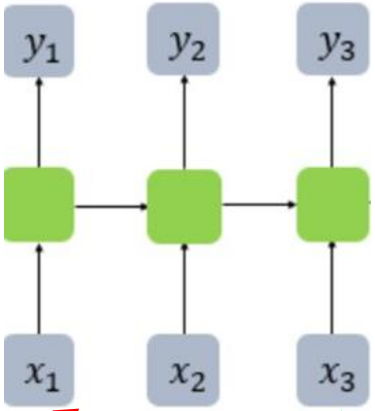

time_step의

첫 번째 단위부터 x1 자리로 들어간다.

	f_1	f_2	f_3	f_4
t_1				
t_2				
t_3				

3. RNN 용어 정리 1) X

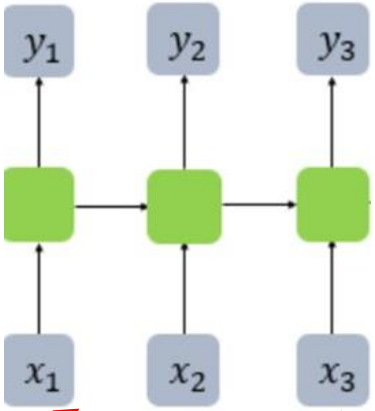

time_step의

첫 번째 단위부터 x1 자리로 들어간다.

	f_1	f_2	f_3	f_4	
t_1	6/29/2010	19.000000	25.00	17.540001	23.889999
t_2	6/30/2010	25.790001	30.42	23.299999	23.830000
t_3	7/1/2010	25.000000	25.92	20.270000	21.959999

3. RNN 용어 정리 2) Cell

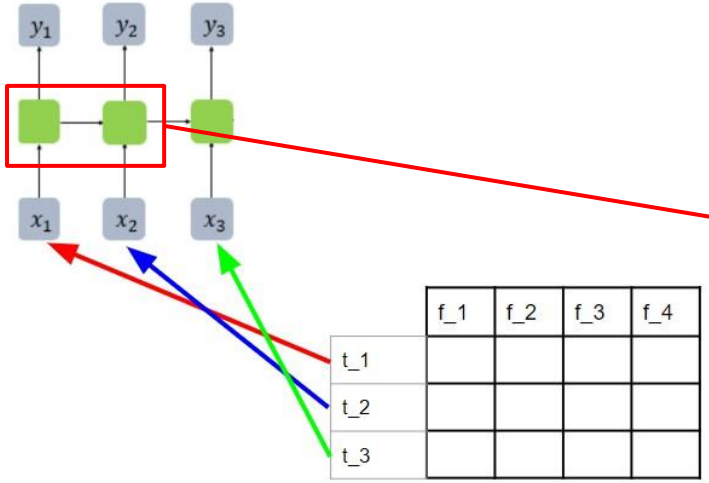

Cell : RNN의 기본 구성 단위

(FC layer 하나가 Cell 1개와 유사)

3. RNN 용어 정리 2) Cell

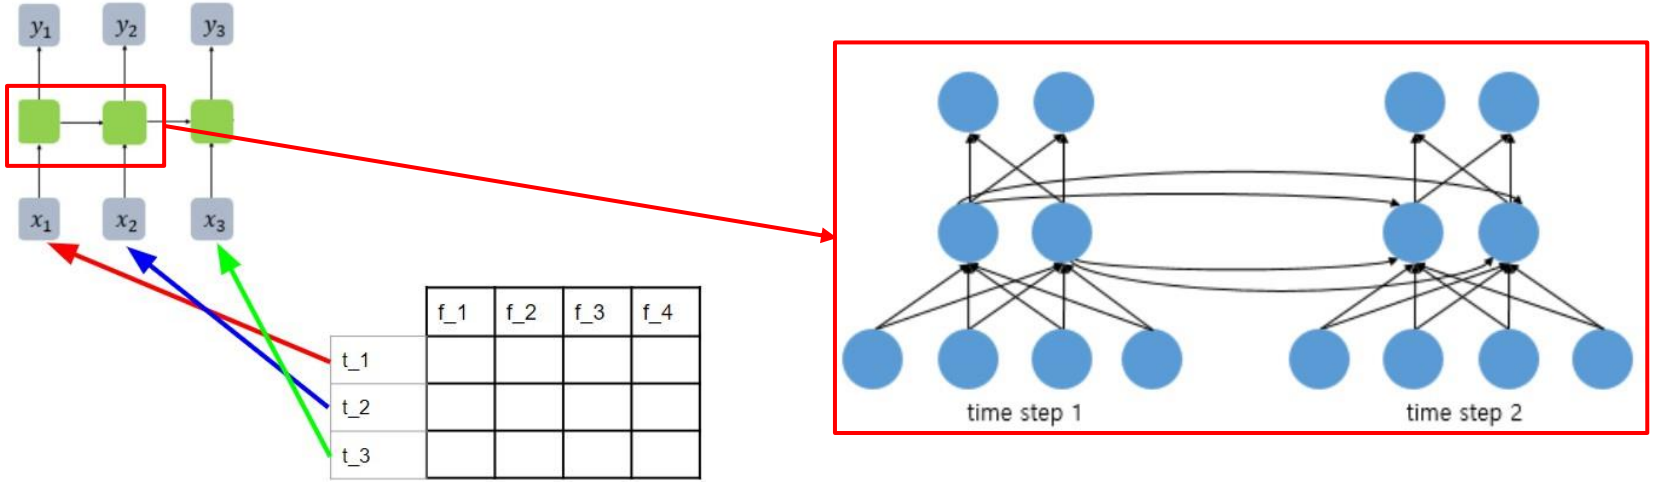

1> unit: 말 그대로 Cell 내부의 hidden unit 개수

2> hidden_state: hidden unit에서 연산한 결과

RNN 구조에 대한 정리

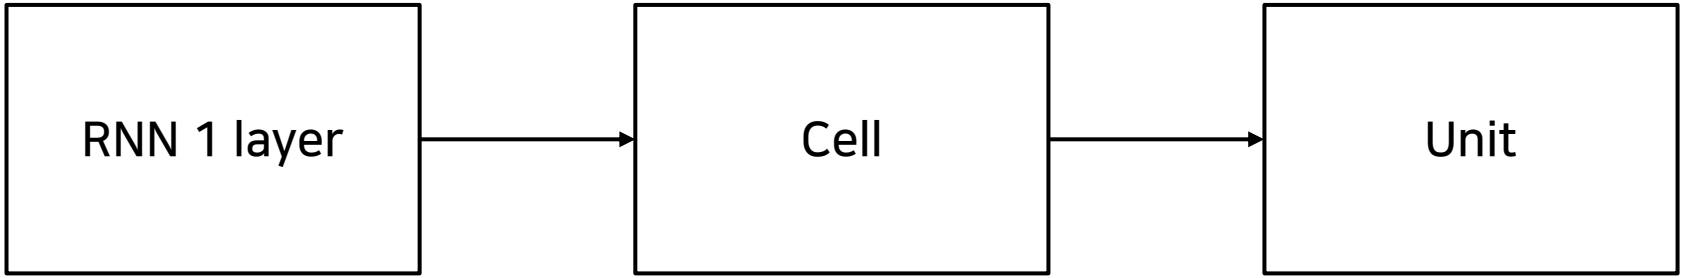

그림으로 각 구조를 한 번 더 보겠습니다.

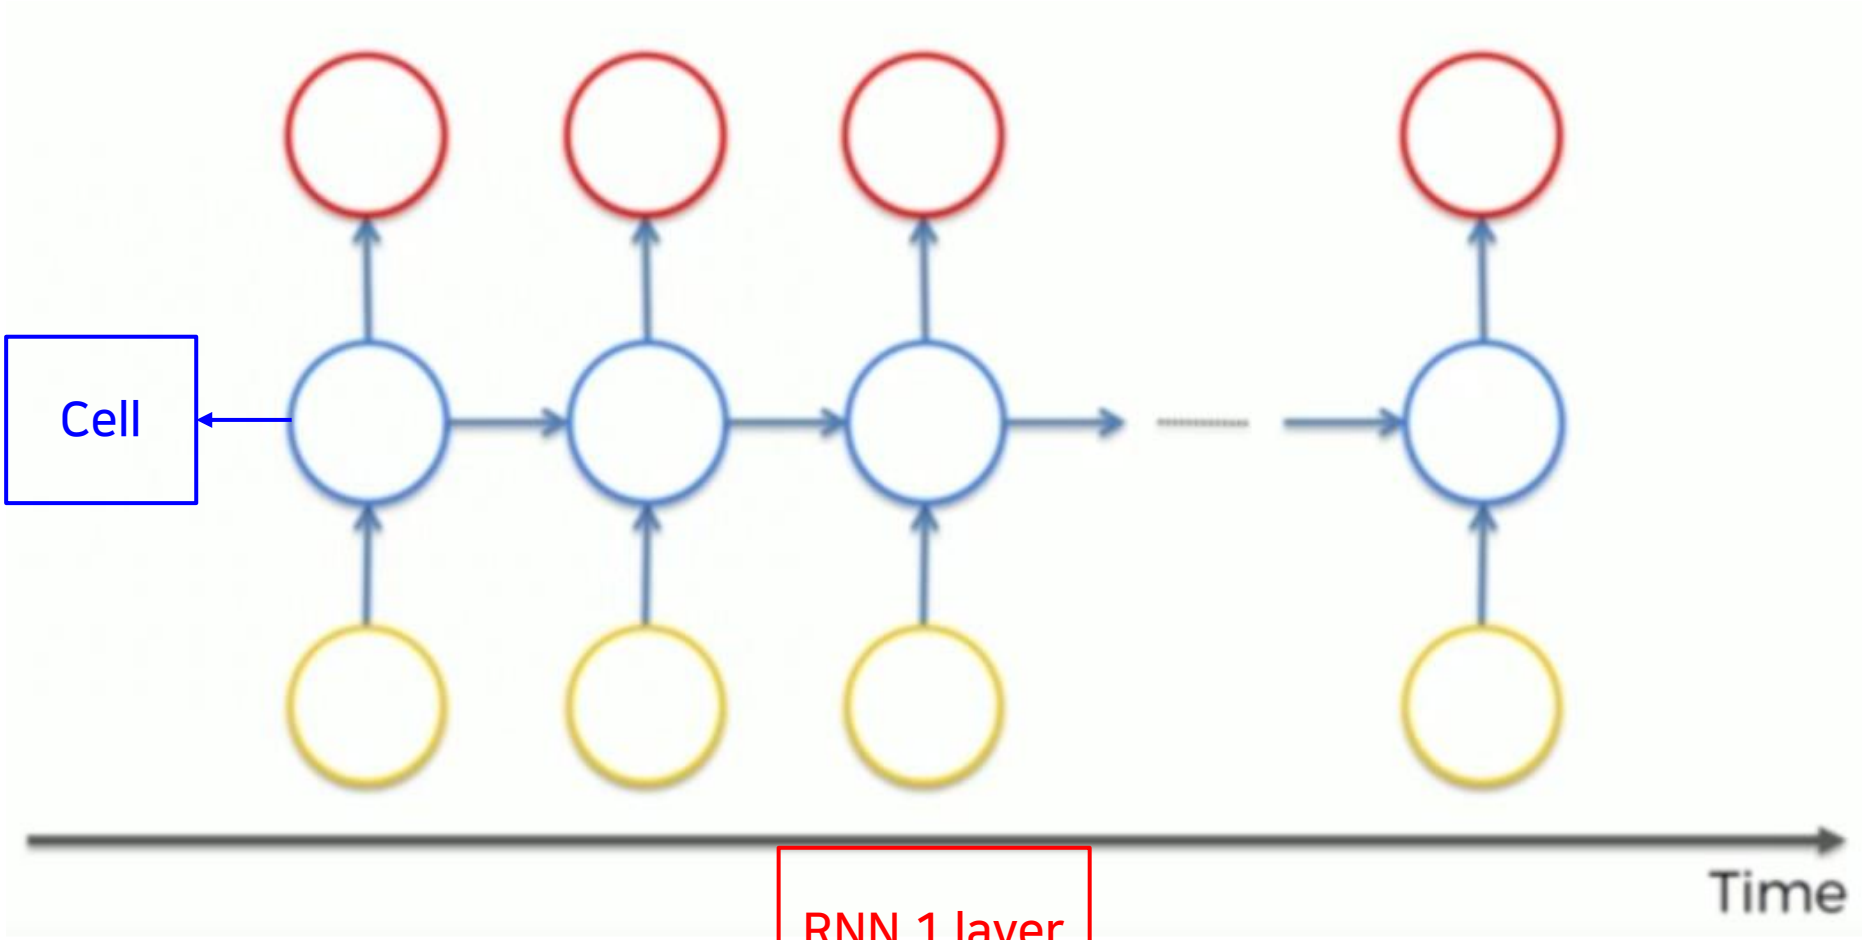

RNN 1 layer

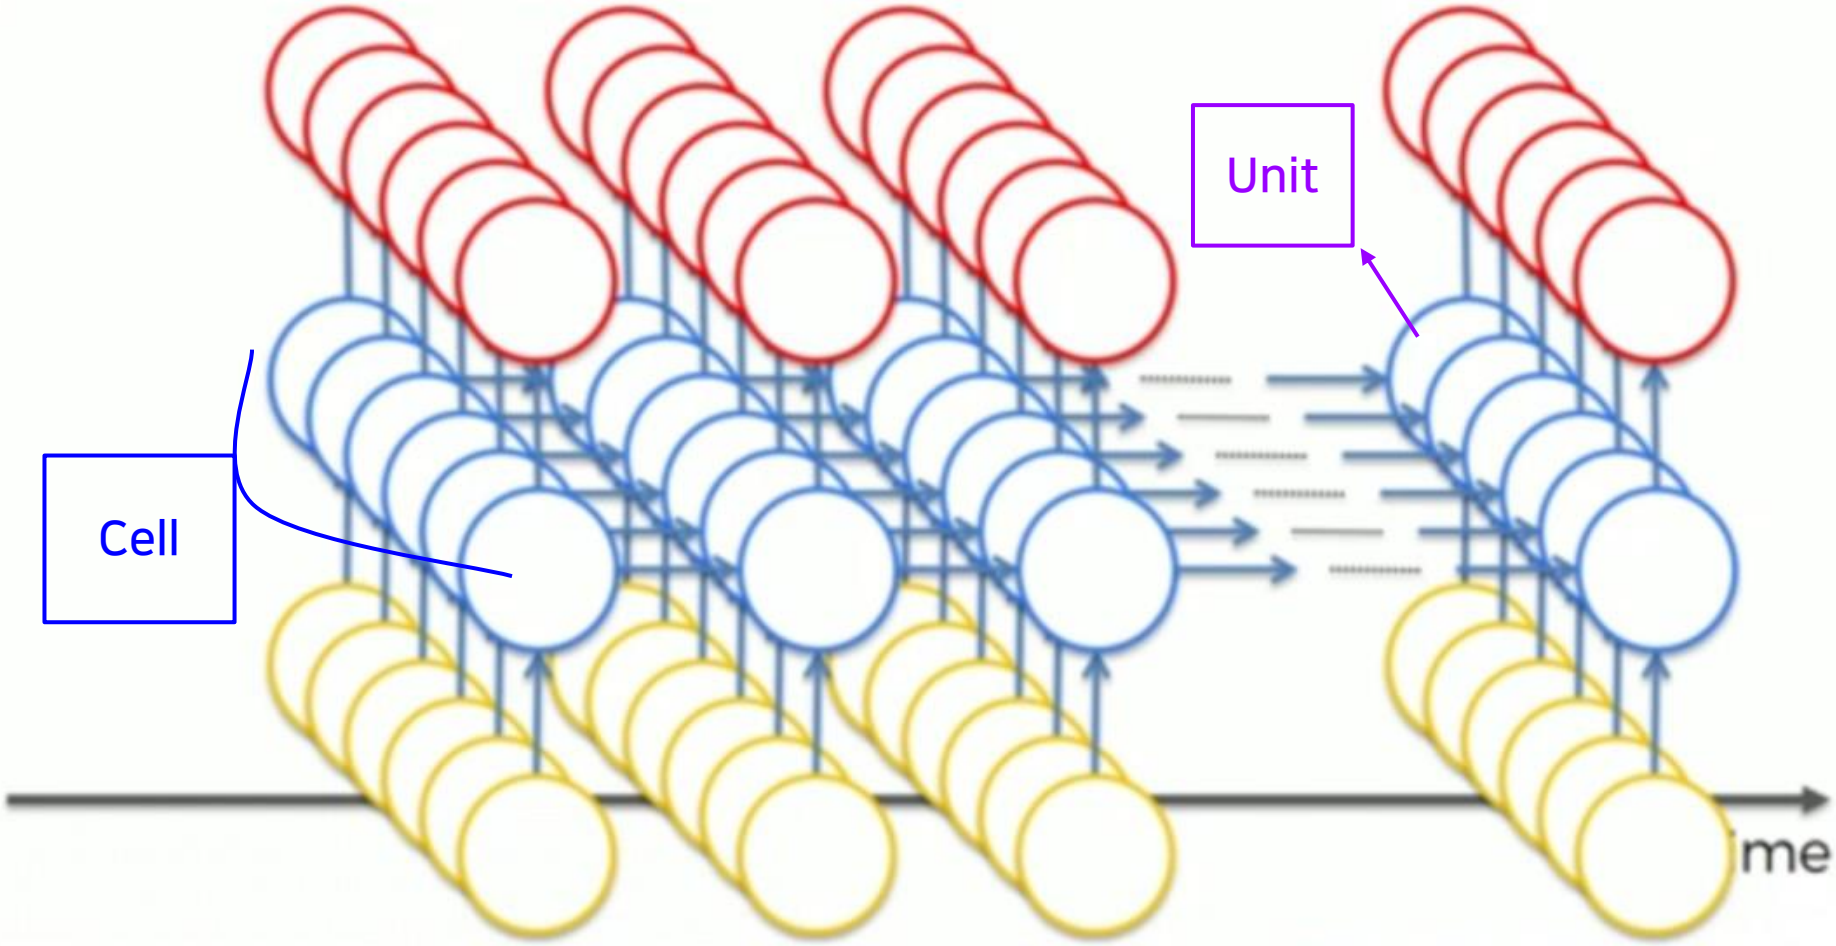
Unit
Cell
me

그래서 어떤 방식으로

input도 고려하고

이전 input들의 연산 결과인 hidden_state도 한 번에 고려하는가?

4. RNN Computation 1) Cell 연산

$$h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t)$$

3가지 단계로 나누어서 보겠습니다.

4. RNN Computation 1) Cell 연산

1> input 연산 (unit)

$$W_{xh}x_t$$

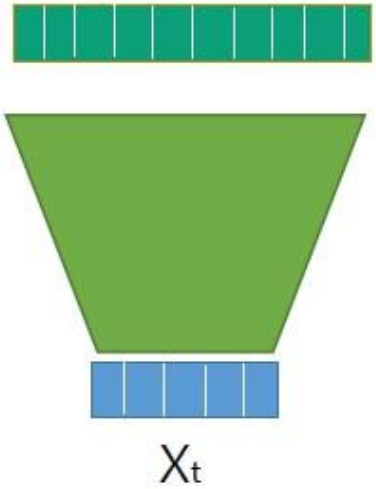

4. RNN Computation 1) Cell 연산

2> hidden_state 연산 (이전 unit의 연산 결과를 받는다.)

$$W_{hh}h_{t-1} + W_{xh}x_t$$

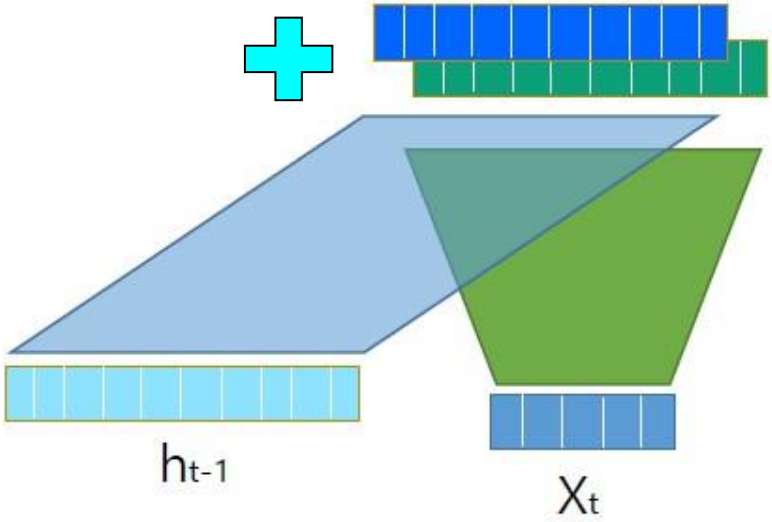

4. RNN Computation 1) Cell 연산

3> activation function

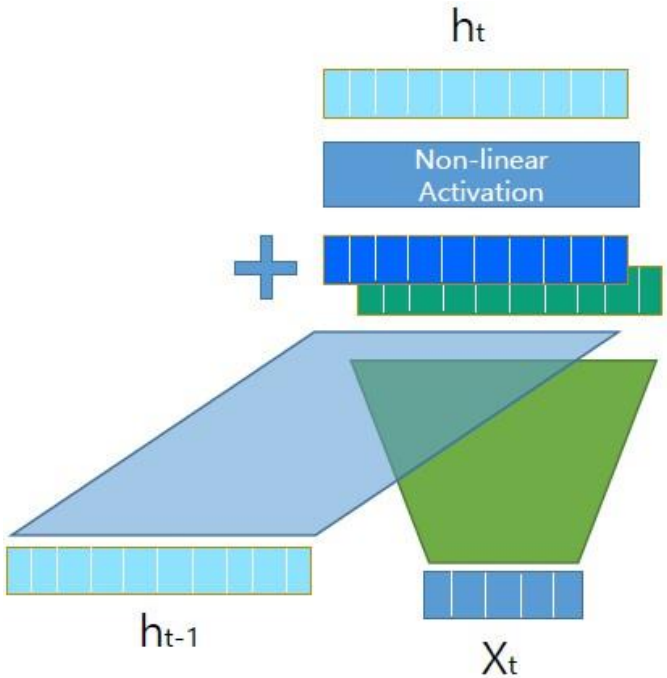

$$h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t)$$

4. RNN Computation 1) Cell 연산

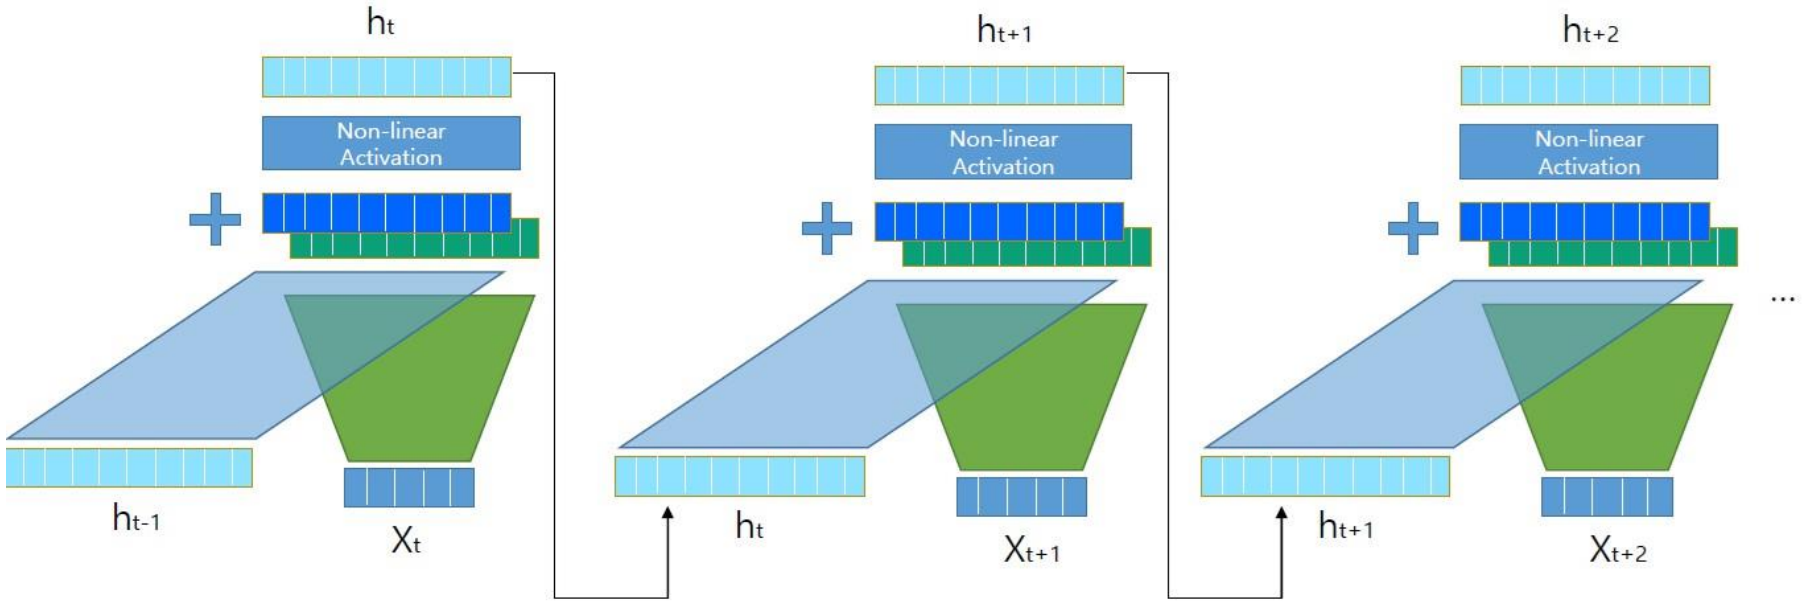

4. RNN Computation 2) output 연산

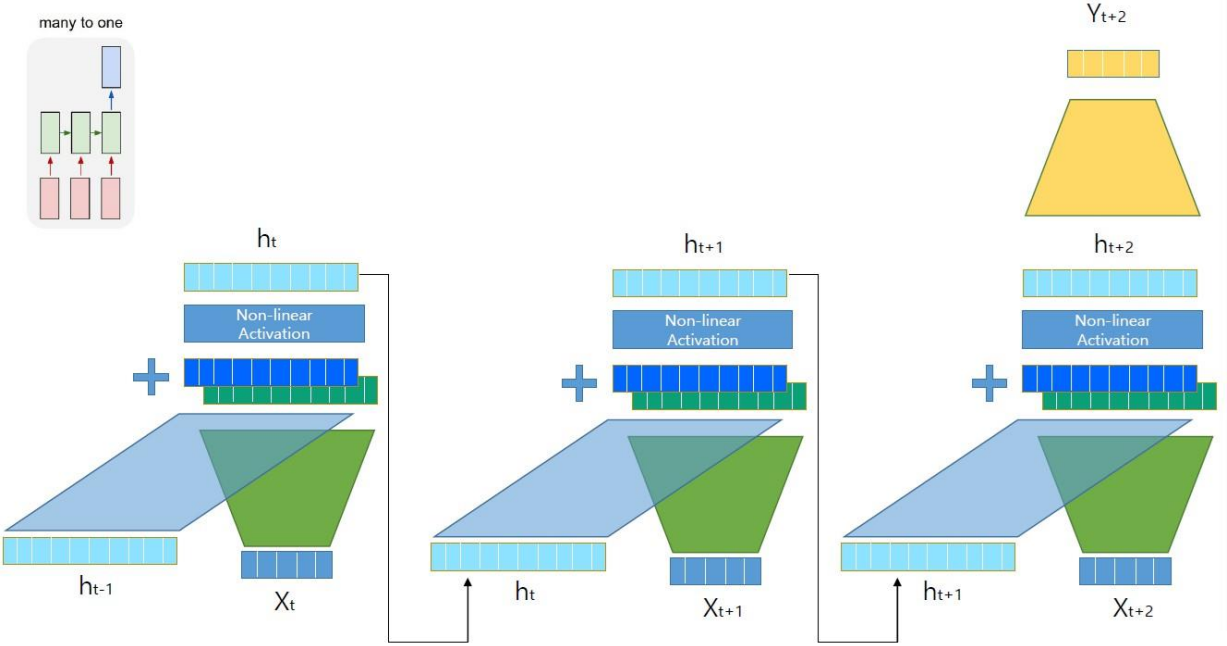

1> return_sequences = False

$$h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t)$$

$$y_t = W_{hy}h_t$$

4. RNN Computation 2) output 연산

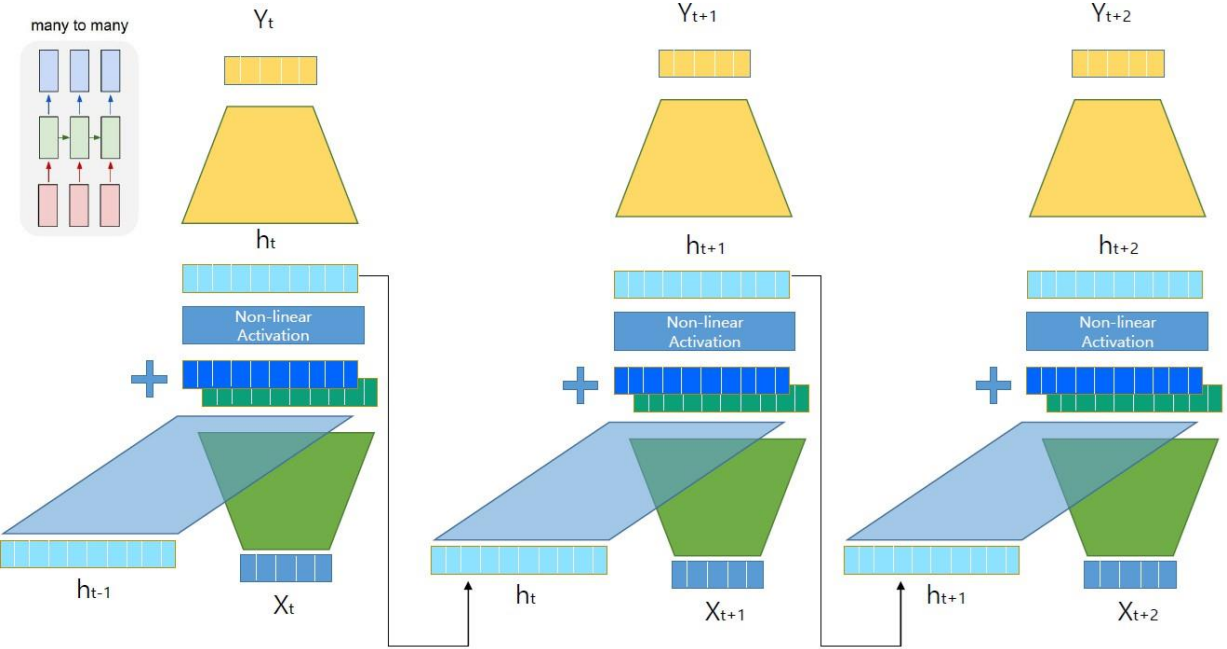

2> return_sequences = True

$$h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t)$$

$$y_t = W_{hy}h_t$$

4. RNN Computation 3) 기타

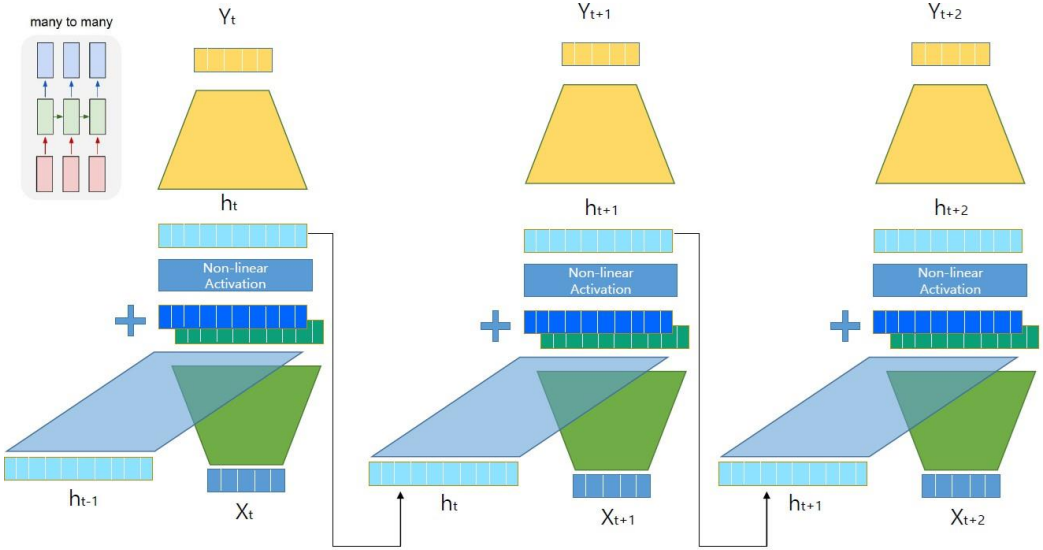

$$h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t)$$

$$y_t = W_{hy}h_t$$

1> Wxh, Whh, Why 모두 동일 layer에서는 그 값이 동일하다.

2> return_sequence를 통해 output의 dimension을 input과 같게 할 수 있고 이를 통해 Recurrent Layer를 더 붙일 수 있다.

5.기타 1) LSTM & GRU

1> LSTM

2> GRU

5.기타 3) 실제 코드

RNN tutorial.ipynb로 수업하겠습니다.

출처

cs231n: http://cs231n.stanford.edu/slides/2019/cs231n_2019_lecture10.pdf
위키독스: https://wikidocs.net/book/2155